



UNIVERSIDAD CENTRAL DE VENEZUELA

FACULTAD DE CIENCIAS ECONÓMICAS Y SOCIALES
ESCUELA DE ESTADÍSTICA Y CIENCIAS ACTUARIALES

ANÁLISIS DESCRIPTIVO DE LA PRODUCTIVIDAD
AGRÍCOLA EN DISTINTAS REGIONES DE LA
INDIA DURANTE EL PERIODO 1997-2009

Trabajo: Informe Académico
Computación I

AUTOR:

Asly Caputo
Aymara Andersen

PROFESOR:

Jesús Ochoa
Oliver Triveño

Índice general

Resumen	III
1. Planteamiento del Problema	3
1.1. Justificación	4
1.2. Objetivos	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	4
1.3. Cobertura	4
1.3.1. Horizontal	4
1.3.2. Vertical	5
1.4. Periodo de Referencia	5
1.5. Variables	5
2. Marco Teórico	6
2.1. Bases Teóricas	6
2.1.1. Tipología de Cultivos	6
2.1.2. Regiones Agrícolas de la India	7
2.1.3. Estadística Descriptiva Univariante	7
2.1.4. Estadística Descriptiva Bivariante	9
2.1.5. Series de Tiempo	10
3. Marco Metódico	11
3.1. Bases metódicas utilizadas en el trabajo de investigación	11
3.1.0.1. Verificación de Datos Nulos	11
3.1.0.2. Selección de Datos Necesarios	12
3.1.0.3. Categorización de Cultivos	12
3.1.0.4. Control de Outliers	12
4. Análisis de Resultados	13
5. Conclusiones y Recomendaciones	18
A. Anexo A	19

B. Anexo B	20
C. Anexo C	21
D. Anexo D	22
E. Anexo E	23
F. Bibliografía	24

Resumen

En el presente estudio se realizará un análisis estadístico descriptivo del sector agrícola en la India, una de las economías a nivel de producción de cultivo más relevantes a nivel global. El objetivo principal es evaluar el comportamiento de la producción, el rendimiento agrícola y el área cultivada en los diversos estados de la India en el periodo comprendido entre 1997-2009. Utilizando el conjunto de datos “Agricultural Crop Yield in Indian States” y herramientas de programación en R y Python se realizará investigación que nos permitirá decir la variabilidad del sector agrícola teniendo en cuenta factores geográficos y los tipos de cultivos. El estudio analiza una muestra de 2223 datos, enfocándose en variables como la Producción (Production), área (Area), y el rendimiento (Yield) además de factores explicativos. Por último, en los resultados se busca identificar las regiones con mayor productividad, la evolución histórica de los rendimientos y la relación entre el tipo de cultivo y la extensión de tierra utilizada.

Introducción

La agricultura es una de las actividades económicas más cruciales en la economía de cualquier país produciendo alimentos, materias primas y generando empleos a gran parte de la población. Asimismo, la India alberga una de las economías agrícolas más grandes del mundo con el 7,5 % de la producción agrícola a nivel global, convirtiéndose en uno de los principales países productores agrícolas del mundo.

A causa de esto, resulta de interés investigar estadísticamente el comportamiento del sector agrícola relacionado con la producción y rendimiento de varios cultivos en la India para responder algunas interrogantes de interés como:

1. ¿Cuáles son las regiones con mayor y menor producción agrícola?
2. ¿Cómo ha evolucionado la producción y rendimiento a través del tiempo?
3. ¿Cómo afecta el tipo de cultivo en el área cultivada?

Por eso, el presente estudio tiene como finalidad realizar un análisis estadístico descriptivo del conjunto de datos “rendimiento de los cultivos agrícolas en los estados de la India” que abarca datos agrícolas de múltiples cultivos plantados en varios estados de la India desde 1997 hasta 2020. Haciendo uso de herramientas para el análisis de datos del lenguaje de programación R y de técnicas de visualización de datos.

Estructura de Informe

- **Capítulo I**, se define el enfoque y propósito del estudio, planteando la problemática del estudio, formulando las preguntas de la investigación, determinando el contexto, límites y objetivos del problema a investigar.
- **Capítulo II**, se establecen las bases teóricas necesarias para entender cómo abordar el problema de estudio, definiendo conceptos primordiales para la investiga-

ción y las técnicas estadísticas necesarias para la resolución del problema.

- **Capítulo III**, se describe la metodología utilizada para el análisis de los datos del estudio, esto incluye la descripción detallada del proceso de limpieza de datos (ETL) y las técnicas usadas para la validación de los datos.
- **Capítulo IV**, se realiza la exposición de los resultados del análisis, respondiendo a las interrogantes de la investigación planteadas en el capítulo I haciendo uso de distintas técnicas de visualización de datos como tablas y gráficos.
- **Capítulo V**, se muestran las conclusiones y recomendaciones basadas en el análisis de los resultados expuestos.

Este estudio busca entender las características del sector agrícola de uno de los principales países productores agrícolas del mundo, analizando su avance y evolución a través del tiempo.

Planteamiento del Problema

La agricultura ha sido un sector económico de la India que ha ido evolucionando a través del tiempo, siendo actualmente uno de los países con mayor producción agrícola a nivel global, lo que lo hace uno de los sectores económicos más relevantes del país. Sin embargo, la agricultura también es un sector con una alta variabilidad cuando hablamos de rendimiento, dependiendo de factores como el tipo de cultivo sembrado y la zona geográfica en la que se encuentra, por lo que obtener una alta producción requiere de un análisis exhaustivo para obtener los mejores resultados.

A nivel económico, la variabilidad del sector agrícola puede suponer un riesgo significativo a la hora de invertir en este sector, por lo que es necesario un estudio como mínimo la compatibilidad entre la región y el tipo de cultivo escogidos, así como su evolución a través del tiempo.

Por eso, resulta de interés analizar estadísticamente el comportamiento y rendimiento de la producción agrícola en la India a nivel general, temporal y geográfico, ya que, independientemente de su gran nivel de producción, es necesario saber la distribución del sector para definir concretamente cual es el sitio más óptimo de inversión.

A partir de esto, se plantean las siguientes preguntas de investigación:

1. ¿Cuáles son las regiones con mayor y menor producción agrícola?
2. ¿Cómo ha evolucionado la producción y rendimiento a través del tiempo?
3. ¿Cómo afecta el tipo de cultivo en el área cultivada?

1.1. Justificación

El presente estudio tiene como justificación la necesidad de conocer e identificar estadísticamente la rentabilidad agrícola de una determinada zona únicamente con los factores básicos que afectan la producción agrícola, sin necesidad de tener un conocimiento profundo del área, lo que permite la toma rápida de mejores decisiones.

Desde un punto estadístico, el explorar y analizar la variabilidad de este sector ayuda a manejar técnicas del análisis descriptivo, haciendo uso de herramientas tecnológicas como lo son los lenguajes R y Python.

1.2. Objetivos

1.2.1. Objetivo General

Realizar un análisis descriptivo de la producción, área cultivada y rendimiento agrícola de las regiones de la India durante el periodo 1997-2009.

1.2.2. Objetivos Específicos

- Comparar la producción, área y rendimiento agrícolas total de la India durante todo el periodo de estudio.
- Identificar los cultivos con mayor área cultivada.
- Identificar el impacto que tiene el área de cultivo según su tipo.
- Evaluar los cambios en la evolución histórica de la producción, área y rendimiento agrícola durante el periodo 1997-2009.
- Cuantificar la relación de la producción de las regiones de la India y los tipos de cultivos.

1.3. Cobertura

1.3.1. Horizontal

La cobertura horizontal abarca las características de cada cultivo registrado y distribuidas en 7 columnas, donde se consideran las dimensiones descriptivas del cultivo y las métricas del rendimiento junto con su relación entre diversos factores agronómicos.

Tabla 1.1: Variables consideradas en el estudio

TIPO	VARIABLE	DESCRIPCIÓN
Categorica	Crop	Nombre del cultivo.
Numerica	Crop_Year	El año en el que se sembró el cultivo.
Categorica	State	Estado de la India donde se sembró el cultivo.
Numerica	Area	Superficie total de tierra (en hectáreas) cultivada.
Numerica	Production	Cantidad de producción agrícola (en toneladas métricas)
Categorica	Crop_Type	Tipo de cultivo sembrado.
Numerica	Yield	Rendimiento calculado del cultivo (producción por unidad de área).

1.3.2. Vertical

La cobertura vertical del trabajo de investigación abarca un total de 2237 observaciones (registros) donde cada fila representa un cultivo específico y sus características correspondientes, con un alcance temporal que abarca desde el año 1997 hasta el año 2009.

1.4. Periodo de Referencia

La fuente de datos a estudiar corresponde al repositorio abierto de Kaggle (“Agricultural Crop Yield in Indian States Dataset”). Donde se toma como período de referencia los registros pertenecientes al intervalo de tiempo 1997-2009.

1.5. Variables

Para este estudio, se tomaron en cuenta como variables principales Production, Area y Yield, las cuales representan la toneladas producidas, las hectáreas cultivadas y su producción por área respectivamente.

También se tomaron como variables explicativas:

1. Variables Temporales: **Crop_Year**
2. Variables Categóricas: **Crop**
3. Variables Geográficas: **State**

Marco Teórico

2.1. Bases Teóricas

En este capítulo se desarrollarán los conceptos y fundamentos estadísticos necesarios para realizar el análisis estadístico necesario para cubrir los objetivos planteados anteriormente. Se abordarán conceptos como la tipología de cultivos, regiones agrícolas de la India y las medidas fundamentales para la Estadística descriptiva Univariante y Bivariante.

Estos conceptos son necesarios para comprender la metodología y resultados de análisis de este estudio y asociarlos al entorno agrícola de la investigación.

2.1.1. Tipología de Cultivos

La India diversifica su producción para satisfacer tanto el mercado interno como el global, en este estudio se analizan 50 variedades de cultivos, por lo que agruparlos puede resultar útil para algunos análisis específicos:

- **Cultivos Alimentarios:** Cereales y legumbres que forman la dieta básica. La India es líder mundial en la producción de legumbres (fuente principal de proteína para su población mayoritariamente vegetariana).
- **Cultivos de Plantación:** Introducidos en gran medida durante la época colonial, se cultivan en grandes fincas para exportación. Destacan el té (Assam y Darjeeling), el café (Karnataka) y el caucho (Kerala).
- **Cultivos Industriales o Comerciales:** Materias primas para la industria manufacturera. La caña de azúcar para el azúcar y el etanol, y el algodón para la potente industria textil india.
- **Horticultura:** Incluye frutas, flores y especias. La India es el mayor productor mundial de especias (pimienta, cardamomo, cúrcuma) y mangos.

2.1.2. Regiones Agrícolas de la India

El país se puede dividir en zonas productivas clave, para el estudio, saber las zonas productivas nos da un indicio de cuáles cultivos pueden tener mayor producción en algunos estados que otras:

- **Región del Noroeste (Punjab, Haryana):** Es la zona más tecnificada y rica. Produce la mayor parte del trigo y arroz del país.
- **Valle del Ganges y Brahmaputra:** Suelos aluviales extremadamente fértiles. Es el reino del arroz, el yute y la caña de azúcar.
- **Cinturón de Suelo Negro (Maharashtra, Gujarat):** Conocido como la "región del algodón". El suelo retiene muy bien la humedad, ideal para cultivos de fibra.
- **Zonas de Plantación del Sur y Noreste:** Las colinas de los Ghats Occidentales y Assam, donde el clima húmedo y la altitud permiten el cultivo de té, café y especias
- **Zonas Áridas (Rajasthan):** Se especializan en mijos y semillas oleaginosas que requieren mínima agua.

2.1.3. Estadística Descriptiva Univariante

La estadística descriptiva univariante se centra en el análisis de datos, haciendo uso de herramientas para describir, tabular, representar y visualizar el comportamiento de una variable.

Para este estudio, será necesario entender el comportamiento individual de la producción, el área cultivada y el rendimiento anual utilizando técnicas de la estadística descriptiva univariante.

Medidas de Posición

Las medidas de posición, también llamadas fractiles o cuantiles, son utilizadas para facilitar la localización de un dato respecto de un conjunto de ellos. Para este estudio, se utilizarán:

- **Cuartiles:** Valores que dividen la serie en 4 partes iguales, cada una de ellas con un 25 % de los datos.

$$P_k = \frac{k(n+1)}{4}$$

- **Mediana:** Promedio no matemático que divide a la serie de datos de un estudio, en dos partes iguales, que representan cada una el 50 % de los datos.

$$Me = \left(\frac{n+1}{2} \right)$$

Medidas de Tendencia Central

Son casos especiales de las medidas de posición, debido a su ubicación en la zona central de la distribución. Estas medidas, también son denominadas promedios.

- **Media Aritmética:** Es el valor resultante más “representativo” de la serie de datos, el punto de equilibrio, el centro de gravedad de la serie.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

- **Mediana:** Promedio no matemático que divide a la serie de datos de un estudio, en dos partes iguales, que representan cada una el 50 % de los datos.

$$Me = \left(\frac{n+1}{2} \right)$$

- **Moda:** Es un promedio no matemático representado por el valor con mayor número de ocurrencias dentro de la serie de datos.

Medidas de Dispersión

Tienen por objeto medir la magnitud de los desvíos de los valores de la variable con respecto al valor central de la distribución, es decir, definen cuán semejante o cuán distinto son cada uno de los valores, de la variable con respecto al valor central.

- **Rango Intercuartílico:** constituye la máxima diferencia posible entre dos valores entre el 50 % de los datos centrales.

$$IQR = Q_3 - Q_1$$

- **Varianza:** Es el promedio cuadrático de los desvíos de los datos respecto de la media aritmética.

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

- **Desviación Típica:** Es la raíz cuadrada positiva de la varianza. Constituye el índice de dispersión más usado y más confiable.

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

- **Coefficiente de Variación de Pearson:** Es el cociente entre la desviación estándar y la media aritmética, multiplicado por cien. Es el coeficiente de dispersión relativa de más amplio uso.

$$CV = \frac{s}{\bar{x}} \times 100 \%$$

2.1.4. Estadística Descriptiva Bivariante

La estadística descriptiva bivalente analiza la relación entre dos variables donde se busca resumir y describir la información conjunta de ambos conjuntos de datos, para identificar patrones y tendencias

En este estudio resulta de interés conocer a fondo el tipo de relación que hay entre cada una de las variables, tanto numéricas como categóricas, para saber la influencia que tienen una sobre a otra.

Medidas de Dispersión Conjunta

- **Coefficiente de Correlación de Pearson:** Es una medida que da cuenta del sentido, dirección e intensidad o magnitud de la relación lineal entre dos variables cuantitativas.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n \cdot \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Método de Detección de Datos Atípicos

Prueba de Tukey

verifica múltiples valores atípicos en ambos lados, categorizados como valores “externos” o “muy alejados”. En este caso los límites son:

- **Límites internos:** Se consideran atípicas leves aquellas observaciones alejadas del 1er y 3er cuartil, respectivamente, más 1,5 veces el Recorrido Intercuartílico.

$$X_i \leq Q_1 - 1,5RI \quad \text{o} \quad X_i \geq Q_3 + 1,5RI$$

- **Límites externos:** Se consideran atípicas extremas aquellas observaciones alejadas del 1er y 3er cuartil, respectivamente, más de 3 veces el Recorrido Intercuartílico.

$$X_i \leq Q_1 - 3RI \quad \text{o} \quad X_i \geq Q_3 + 3RI$$

2.1.5. Series de Tiempo

Una serie de tiempo se conoce como una representación visual de datos donde se observa la evolución, bien sea de días, meses o años. A diferencia de otros conjuntos de datos, en las series de tiempo es sumamente importante que vayan en orden cronológico ya que los valores menores suelen influir en los valores futuros

En la agricultura se puede utilizar la serie de tiempo para medir el año de cosecha y su evolución

Marco Metódico

En este capítulo se describe el proceso de selección de aquellos registros necesarios para cumplir con los objetivos planteados en el capítulo I. Para esto se hará uso de herramientas para el análisis de datos como R y Pandas (librería de Python).

3.1. Bases metódicas utilizadas en el trabajo de investigación

En la presente investigación fijamos una variable cuantitativa a nivel descriptivo, ya que, se busca caracterizar la situación agrícola procesando datos numéricos de la producción, áreas cultivadas y rendimiento agrícola en la India. Dicho esto se utilizó bases metódicas estadísticas integrando datos cuantitativos y cualitativos.

3.1.0.1. Verificación de Datos Nulos

Con la ayuda de Tidyverse utilizando librerías como los son (“dplyr” y “tidyr”), se escanea el dataset en busca de valores nulos que puedan afectar el análisis. Dando como resultado la ausencia de datos nulos en todas las columnas del dataset original.

Por lo tanto, podemos decir que no hay datos nulos en el dataset a trabajar.

##	Crop	Crop_Year	Season	State	Area
##	0	0	0	0	0
##	Production	Annual_Rainfall	Fertilizer	Pesticide	Yield
##	0	0	0	0	0

3.1.0.2. Selección de Datos Necesarios

Como se mencionó en el Capítulo I, se tomarán los registros anuales entre el periodo de 1997 hasta el 2009. Esto implica que las variables “Crop_Year” y “Season” serán filtradas según esas condiciones.

Aparte, se seleccionan únicamente las columnas que contengan las variables necesarias para el estudio, es decir:

Crop, Crop_Year, Production, Area y Yield.

3.1.0.3. Categorización de Cultivos

Para facilitar el análisis, se agruparon sectores de cultivos creando nueva información colocada en etiquetas. Un cultivo como “Arroz” y “Frijoles” se colocó en la nueva Variable (Crop_Year) como “Cereales y Granos” , permitiendo comparar el crecimiento de cereales básicos con legumbres o cultivos comerciales.

3.1.0.4. Control de Outliers

Para visualizar correctamente la distribución de alguna variable numérica como Production, Area ó Yield, es necesario identificar la cantidad de valores atípicos de cada una, para ello se utilizó el método del rango intercuartílico, con el fin de saber la cantidad de outliers de cada una y el porcentaje que ocupan en la variable.

##	Variable	Registros	Total_Atípicos	Porcentaje
## 1	Produccion	2238	435	19.44
## 2	Area	2238	286	12.78
## 3	Rendimiento	2238	337	15.06

Análisis de Resultados


{Este capítulo presenta los resultados obtenidos al aplicar las metodologías descritas en el capítulo anterior, así como del análisis estadístico descriptivo de las variables estudiadas y las ventajas y desventajas al aplicar dichos tests.}

MEDIDAS DE TENDENCIA CENTRAL Y DISPERSIÓN

Tabla 4.1: Medidas de Tendencia Central y Dispersión

Indicador	Media	Mediana	Desviación_Típica
Production	68741614.34	24762.00	537174070.52
Area	67723.38	7476.50	238939.79
Yield	336.74	3.84	1732.53

REGIONES CON MAYOR Y MENOR PRODUCCIÓN




Al observar el grafico, tenemos como resultado una distribución desigual. Las regiones del norte y el centro del país presentan una actividad muy escasa, mientras que el sur y zonas montañosas del país aparecen con color más intenso, lo que nos indica que la producción agrícola es más alta.

Respondiendo así a la pregunta principal ¿Cuáles son las regiones con mayor y menor producción agrícola?.


Los estados con mayor producción se encuentran al sur de la India, teniendo a Kerala como el estado con más de 74000 millones; mientras que Jammu and Kashmir se sitúa como el estado con menor producción agrícola con un total de 63330.

¿CÓMO HA EVOLUCIONADO LA PRODUCCIÓN Y EL RENDIMIENTO A TRAVÉS DEL TIEMPO?



El gráfico de evolución temporal, el cual indica la respuesta a nuestro objetivo numero 2, nos muestra un crecimiento constante. Desde 1997 hasta el año 2009, no ha decaído en ningún momento. Aunque se muestran pequeños saltos entre años (subidas y bajadas) probablemente causados por el clima, la tendencia general es muy positiva; demostrando que la India no solo ha mantenido el ritmo de producción, sino que produce cada vez más.

¿CÓMO AFECTA EL TIPO DE CULTIVO EN EL ÁREA CULTIVADA?



En el análisis de las barras observamos que la papa, el banano y la caña de azúcar son los cultivos que lideran el volumen de producción general, afectando de manera positiva en cuanto a su rendimiento. Destacan por su eficiencia por área, ya que producen mucho en poco espacio. Al enfocarse en estos cultivos esto le permite al país tener más ganancias y asegurar alimento para la población.

MATRIZ DE CORRELACIÓN DEL ÁREA, PRODUCCIÓN, Y RENDIMIENTO AGRÍCOLA

Tabla 4.2: Matriz de Correlación de Producción, Rendimiento y Área

	Production	Area	Yield
Production	1.000	0.280	0.543
Area	0.280	1.000	0.102
Yield	0.543	0.102	1.000

Relacion entre produccion y rendimiento ($r = 0.543$): La relación más clara está entre la producción y el rendimiento. Esto nos dice que el volumen total de la cosecha depende principalmente de qué tan bien se aprovecha cada hectárea. Básicamente, si quieres producir más, la clave es mejorar la eficiencia de tus cultivos.

Relacion entre produccion y area ($r = 0.280$): La relación entre la Producción y el Área es baja. Esto significa que sembrar más tierra no provoca automáticamente un gran salto en la producción total. En la práctica, es mucho más efectivo trabajar con lo que ya tienes que simplemente tratar de expandirse a más hectáreas.

Relación entre terreno y rendimiento ($r = 0.102$): Casi no hay relación entre el tamaño del terreno y el rendimiento. Esto indica que la eficiencia es la misma sin importar si la parcela es pequeña o grande. No estás ganando beneficios extra por ser más grande, pero tampoco estás perdiendo calidad al crecer.

Conclusiones y Recomendaciones

Después de realizar el análisis de datos en el presente estudio y observar la evolución de la producción podemos concluir lo siguiente:

1.- En el periodo del año 1997 hasta el 2009 la agricultura tuvo una evolución constante, aunque tuvo altas y bajas a causa principalmente del clima al pasar los años se visualizó que nunca dejó de crecer su producción.


Recomendación Tener en cuenta la temporada en la que se cultiva para que el clima no sea un factor en contra y así poder tener mejor rendimiento con respecto a la producción.


2.- Se determinó que los sectores con mayor producción son aquellos ubicados al sur de la India, siendo esos los estados más montañosos. Esto nos permite concluir que la producción está ligada a la geografía, concentrándose en las zonas donde hay mejor tierra, su clima es más húmedo y cuenta con zonas más altas, lo que permite una mejor cosecha.


Recomendación Priorizar los cultivos que se producen en esta área. Sin embargo, tomando en cuenta que son sitios húmedos y suelen contar con la existencia de hongos, se recomienda tomar las medidas necesarias para que los cultivos no sufran ningún tipo de daño.


3.- Por último se observó que los cultivos con mayor producción (papa, banana, cebolla) son los cultivos que tienen mayor impacto en el área de alimentos y economía.


Recomendación Enfocarse principalmente en estos cultivos a la hora de su producción, de manera que logre ser considerado una fuente principal de ingresos y alimentos.











Bibliografía

1. Pinto, S. & Salomón, M. (2015): Análisis descriptivo univariante, material docente. Caracas: Escuela de Estadística y Ciencias Actuariales - UCV.
2. Jairo A. Ayala Godoy RPubS by RStudio
3. Tipos de agricultura en India GeeksforGeek <https://www.geeksforgeeks.org> > types-of-agriculture